

研究紹介

ネットワークコンピューティング研究室
cm26069 藤田捷平

目次

- 1.はじめに
- 2.関連研究
- 3.提案手法
- 4.性能評価
- 5.まとめ

はじめに

研究背景

英語で会話することに苦手意識のある日本人が少なからず存在し、実際の年齢よりも会話した際に**子供っぽく (childish)**聞こえることが考えられる。

仮説

子供っぽく聞こえることは、発話者の評価を下げる原因になると考える

目的

練習者の発話音声をもとにAIにより解析し、発話者が子供っぽくない発話をするための助言を与えるシステムの構築

関連研究

Tagami 達の手法 [1]

- ・ 深層学習を用いた英語プレゼンテーション練習システム

本研究の提案手法と同様に，練習者の音声を受け取り解析し，改善の助言を出力している．さらに，目標とする発話方法に近づけるための助言の出力に特化している．

※大人っぽさや，子供っぽさに関する練習を行うことの支援はできないもの．

関連研究

Attention Is All You Need[2]

- Vaswani達は、RNNやCNNを用いずAttentionを用いるTransformerというモデルを提案した。
- 以前（2017年）の機械翻訳では、RNN (Recurrent Neural Network), CNN (Convolutional Neural Network)とAttentionを用いて行っていた。
- Transformerでは、RNNやCNNを用いず、Attentionを用いる
- Attentionは、入力文のどの単語に注目するかを示すもの。

[2] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Łukasz Kaiser, and Illia Polosukhin. 2017. Attention is all you need. In Proceedings of the 31st International Conference on Neural Information Processing Systems (NIPS'17). Curran Associates Inc., Red Hook, NY, USA, 6000–6010.

提案手法

本発表では、発話練習者の音声をAIで解析し、AIが子供っぽいと判断した根拠を練習者に提示し、練習者が指摘点を改善することにより子供っぽくない発話を実現する手法を提案する

子供っぽい音声：

AIにて、こどもの発話音声と、大人の発話音声を学習して判断モデルを作成し、そのモデルが「子供の音声である」と推論した音声は子供っぽい音声であるとみなす

提案手法

1. 大人の音声と，子供の音声を用いて，教師あり学習を行い音声が大人のものであるか，子供のものであるかを推論するモデルを作成する.
2. 練習者が自分の音声を入力し，モデルにその入力音声が大人のものであるか，子供のものであるか推論させる.
 - ここで「子供」と判定された場合のみ，以下に進む
3. 子供の音声であると推論された場合はその判断根拠を，モデルに出力させる.
 - 具体的には「Attentionが高い部分」を判断根拠とする
4. 練習者は提示された箇所を重点的に練習する.

性能評価

使用音声	個数
Common voice(adult):訓練データ	200
Hugging face(child):訓練データ	200
Common voice(adult):検証データ	100
English children(child):検証データ	100
練習者の音声データ:テストデータ(1)	1
提案システムから指摘された部分を重点的に練習:テストデータ(2)	10
ランダムな箇所の練習:テストデータ(2)	10

実際に提案手法を用いて英語練習を行い、提案手法の有効性の評価を行った。

→ 提案手法を用いて練習した例と、
用いずに練習した例の音声を比較

・判断モデルの構築：common voiceの20～30代の音声と、hugging faceの子供音声を訓練データとして、教師あり学習を行い、音声の大人か子供かを判断するモデルを構築。

・練習者の音声をテストデータ(1)としてモデルに推論させ、単語ごとにAttentionを求める。


音声が子供の音声と判断された場合は、
その判断根拠(高Attention語)を練習者に提示

・練習者は、**提案手法を用いて** または **用いずに** 発話練習し、練習結果の音声をテストデータ(2)として、上記判定モデルで評価。

用いて：指摘された部分を重点的に練習

用いずに：ランダム選択部を重点的に練習

性能評価：事例1（単語ごとのAttention）




読んだ文は“Hi I'm Shohei. Nice to meet you.”

提案手法の助言：Attentionの高い単語(Hi I'm Shohei)を声を大きくして読む

ランダム手法：無作為選択の語を声の大きくして読む

性能評価結果



各手法の推論結果(子供音声である確率)をグラフに示す.

練習前, 提案システム練習後の10個の音声の平均, ランダム練習後の10個の音声の平均

練習前の子供音声である確率は0.999である.

提案システム練習後は0.915

ランダム練習後は0.976

baseline(ランダム練習)よりも,
提案システムの練習後の方が,
こどもっぽさが低くなった

性能評価

	練習前 の音声	練習後 (提案 手法)	練習後 (ラン ダム)
1回目	0.999	0.841	0.993
2回目		0.962	0.974
3回目		0.994	0.918
4回目		0.94	0.98
5回目		0.81	0.99
6回目		0.925	0.954
7回目		0.863	0.996
8回目		0.989	0.974
9回目		0.935	0.996
10回目		0.891	0.993
平均	0.999	0.915	0.976

練習前，提案システムの指摘箇所の実習後10回の音声，ランダム選択箇所の実習後10回の音声の，モデルによる推論結果(子供音声である確率)を左表に示す．

指摘箇所を意識して読んだ際に0.8代(赤字)の値が出力されたものが4つ確認され、ランダム箇所の練習後の音声よりも改善された箇所が多い．

提案手法の精度評価 (藤田)

前回の実験でA/Cである程度変えられたのでもう一度提案手法の検証を行う。

1. Attentionの高い部分の単語のスピードの速度を上げる。
2. Attentionの高い部分の単語の音の高さを低く変化させる。
3. Attentionの高い部分を声を大きくして変化させる。

比較する音声: 練習前の音声, 自分の声の高Attention語を判断根拠として声を大きくして読んだ際の音声, ランダムで声を大きくしたものを100個ずつの子供音声である確率。

読んだ文章

- People-look-but-no-one-ever-finds-it.

判断根拠

グラフから People, look, but を判断根拠にした。



提案手法の精度評価（藤田）1 - 2

（平均,信頼区間,最大最小）

練習前、練習後（スピードアップ、声の高さ低く、声を大きく）子供度の100個の音声の平均と最大と最小と信頼区間を示した。

	練習前	スピードアップ	声の高さ低く	声を大きく
平均（子供度）	0.9855	0.9433	0.9255	0.9877
最大	0.9991	0.9920	0.9935	0.9993
最小	0.9551	0.8329	0.8725	0.9644
信頼区間	0.9898~0.9936	0.9399~0.9467	0.9229~0.9281	0.9869~0.9885

子ども音声である確率の平均値に関して声の高さ低くした際の平均が他の三者より一番低く、次にスピードアップ、最後に声を大きくだったが、声を大きくした際は練習前に勝つことはできなかった。最小は声を低くとスピードアップが0.8代に到達した値があった。

まとめ

本研究では発話者が英語の発音をし，AIが声や発音の特徴を判定し，発話が子供っぽく聞こえないようにするための助言を生成する手法を提案した。

性能評価により提案手法の有効性や課題点を示した。

今後の方針

- ・ 文を増やして行う
- ・ 被験者を増やして実験を行う。